

---

# CONTINUAL LEARNING ON HANDWRITTEN DIGIT RECOGNITION USING DEEP LEARNING

---

A PREPRINT

✉ **Vincent Pangestu**

Department of Computer Science  
Bina Nusantara University  
Alam Sutera, Indonesia  
vincent.pangestu001@binus.ac.id

✉ **Edward Lokadinata**

Department of Computer Science  
Bina Nusantara University  
Alam Sutera, Indonesia  
edward.lokadinata@binus.ac.id

✉ **Bryan Marcello Layvin**

Department of Computer Science  
Bina Nusantara University  
Alam Sutera, Indonesia  
bryan.layvin@binus.ac.id

## ABSTRACT

Handwritten Digit Recognition merupakan kecerdasan komputer untuk mengenali suatu angka yang ditulis oleh manusia. Tidak seperti kecerdasan manusia, hal tersebut merupakan hal yang cukup sulit bagi komputer karena penggambaran angka yang dituliskan pasti beragam. Terdapat beragam model yang bisa digunakan untuk membantu komputer dalam memecahkan masalah diatas. Dalam paper ini, kami berfokus pada model Neural Network untuk membantu komputer mengenali dan memprediksi angka tulisan tangan manusia dari data yang kami gabungkan dan buat sendiri, dari angka 0 - 9. Model Neural Network yang kami kembangkan tersebut memiliki akurasi sekitar 99% dengan menggunakan 2 hidden layer dari keseluruhan data yang kami gunakan.

**Keywords** Continual Learning · Handwritten Digit Recognition · Deep Learning

## 1 Introduction

*Deep Learning* adalah teknik pembelajaran mesin yang mengajarkan komputer untuk melakukan hal alami yang dilakukan oleh manusia: contohnya adalah "Belajar". *Deep Learning* juga merupakan subbidang *machine learning* yang algoritmanya terinspirasi dari struktur otak manusia.

*Continual Learning* (disebut juga *Incremental Learning*, *Life-long Learning*) adalah suatu konsep untuk mempelajari suatu model untuk sejumlah besar tugas secara berurutan tanpa melupakan pengetahuan yang diperoleh dari tugas-tugas sebelumnya, dimana data dalam tugas-tugas lama tidak tersedia lagi selama pelatihan. yang baru. Dalam *handwritten digit recognition*, kami menghadapi banyak tantangan karena gaya penulisan yang berbeda dari orang yang berbeda seperti itu bukan pengenalan karakter Optik.

*Handwritten digit recognition* adalah kemampuan komputer untuk mengenali angka tulisan tangan manusia dari berbagai sumber seperti gambar, kertas, layar sentuh, dan mengklasifikasikan mereka ke dalam 10 kelas yang telah ditentukan (0-9). Ini telah menjadi topik penelitian tanpa batas di bidang *deep learning*. *Digit recognition* memiliki banyak aplikasi seperti plat nomor pengakuan, penyortiran surat pos, pemrosesan cek bank, dan lainnya. Dalam pengenalan digit tulisan tangan, kami menghadapi banyak tantangan.

## 2 Previous Research

Recognition of handwritten MNIST digits on low-memory 2 Kb RAM Arduino board using LogNet reservoir neural network, code dari research ini compact dan juga simple agar dapat digunakan diberbagai tempat. Dengan menggunakan LogNet didapatkan akurasi 82% dengan jumlah neuron yang sedikit, dikarenakan ini menggunakan memori RAM yang rendah maka dapat digunakan dimana saja. Dengan akurasi diatas 80% dan dapat digunakan pada memori RAM yang kecil LogNet model yang cukup bagus untuk digunakan.

Effective Handwritten Digit Recognition using Deep Convolution Neural Network, hanya dengan epoch yang kedua data training dapat diberhentikan karena sudah mencapai akurasi yang diinginkan dengan loss yang sedikit juga. CNN menjadi model yang bagus untuk handwritten recognition, karena dengan menggunakan CNN akurasi yang didapatkan yaitu 98%. Tetapi karena image dari tulisan tangan asli memiliki noise, hal ini merupakan tantangan bagi model ini.

How Important Is Weight Symmetry in Backpropagation?, dengan menggunakan Symmetry Backpropagation dilakukan banyak eksperimen untuk menemukan model yang tepat dengan membandingkan hasil dengan performa SGD. ketika dilakukan fixed random feedbacks, performa tidak ada yang melebihi atau lebih buruk daripada baseline SGD. Dengan mengubah setting dari Batch Manhattan dapat memberikan performa yang mirip dengan baseline SGD, tidak lebih dan tidak kurang. Dari sini dapat kita lihat bahwa Batch Normalization dan Batch Manhattan berperan penting untuk melakukan asymmetric backpropagation. Research ini membuktikan bahwa asymmetric backpropagation tidak lebih buruk daripada backpropagation biasa.

## 3 Methodology or Architecture

### 3.1 Neural Network

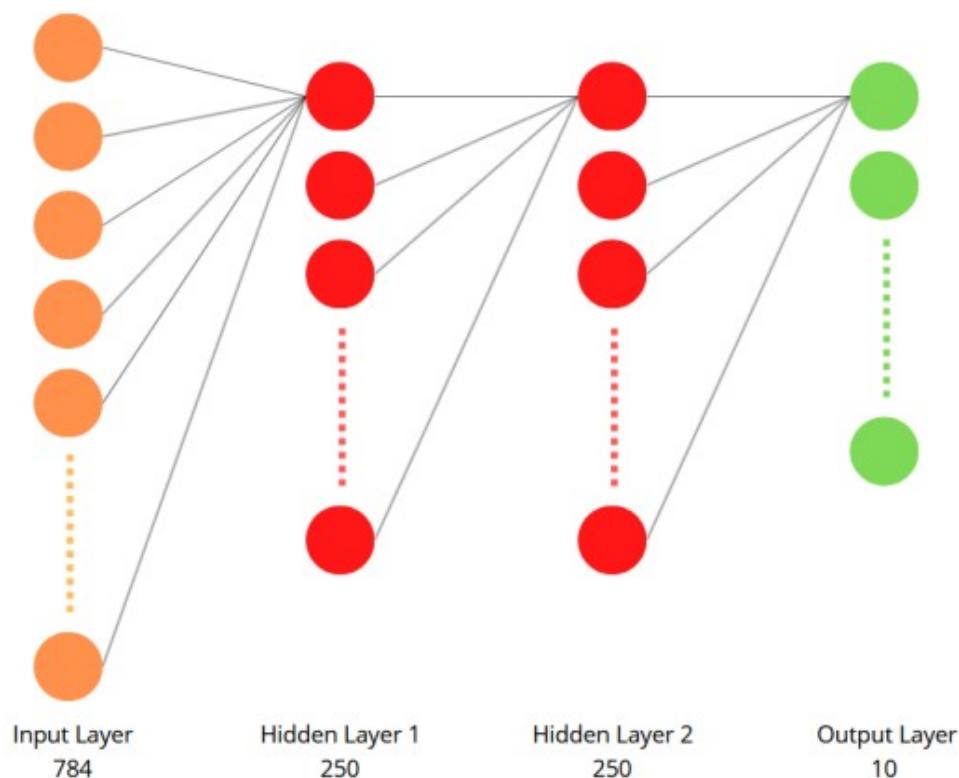


Figure 1: Gambaran model yang digunakan

CNN merupakan jenis lain dari neural network yang dapat mengungkap informasi deret waktu dan data gambar. Dalam mengidentifikasi pola dalam gambar, CNN menggunakan prinsip dari aljabar linear, seperti perkalian matriks.

Arsitektur dalam CNN biasanya dianalogikan seperti pola konektivitas otak manusia. Otak manusia terdiri dari milliaran neuron, CNN juga memiliki banyak neuron yang memiliki susunan dan sistemnya yang teratur. Susunan ini memastikan seluruh bidang visual bisa tercakup, sehingga dapat menghindari masalah saat melakukan proses pada gambar. Berbeda dengan neural network lain, CNN memiliki kinerja yang lebih baik.

Neural Network merupakan salah satu algoritma Machine Learning yang sering digunakan untuk klasifikasi gambar. Neural Network yang digunakan akan terdiri atas satu input layer, satu output layer, dan dua hidden layer. Gambar yang telah diproses akan dimasukkan kedalam input layer dengan aturan tiap kanal input menerima data dari satu 1 pixel. Jumlah pixel dari tiap gambar adalah  $28 \times 28 = 784$ , oleh karena itu input layer akan memiliki 784 kanal input. Pada output layer, ditentukan akan memiliki 10 neuron yang didapat dari jumlah class output (0 - 9). Pada input dan hidden layer digunakan activation function sigmoid sedangkan pada bagian output layer digunakan activation function softmax.

Kemudian pada bagian backpropagation, function yang digunakan merupakan turunan (derivative) dari function diatas. Untuk mencegah terjadinya nilai yang overflowing pada  $e^x$ , maka nilai x akan dikurangi nilai maks dari [x].

### 3.2 Dataset

Dalam paper ini, kami menggunakan 2 dataset yaitu *self made dataset* yang terdiri dari 11,789 gambar dalam format png sehingga perlu dilakukan *preprocessing* dan *MNIST dataset* yang terdiri dari 60,000 gambar yang kami split jadi 50,000 training set dan 10,000 test set.

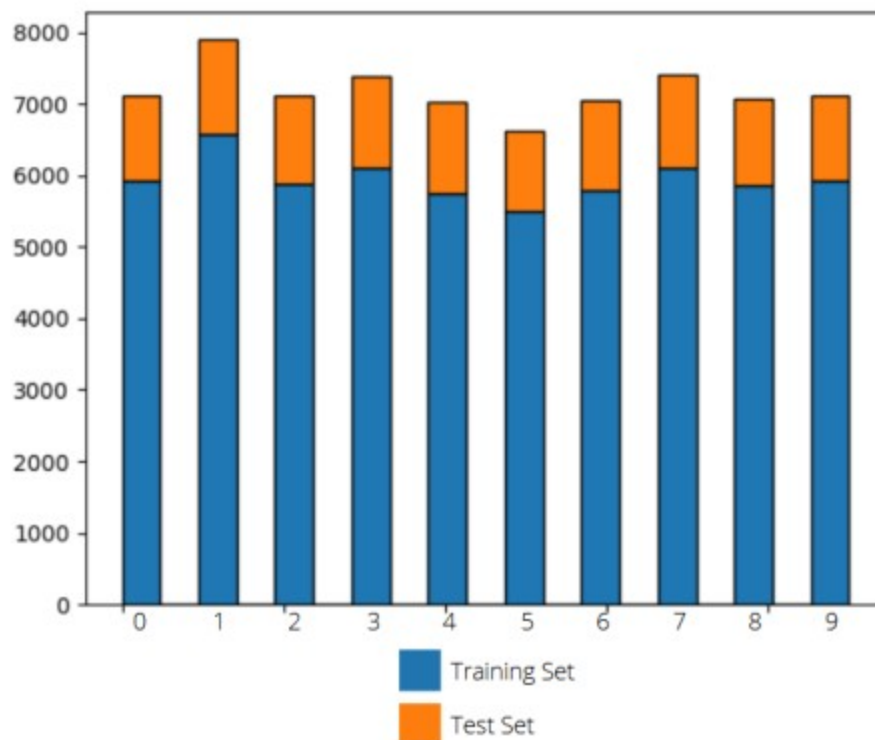


Figure 2: Persebaran dataset

### 3.3 Pre-processing




Figure 3: Contoh data dari self-made dataset

Tahapan pertama yang dilakukan adalah memproses self-made dataset. Tiap gambar akan diconvert menjadi ukuran 28x28 pixel. Setelahnya itu, akan dilakukan pengekstrakan inverted grayscale value dari gambar tersebut yang berbentuk sebuah numpy array.




Figure 4: Pengekstrakan Grayscale Value dari sebuah gambar

Setelah itu dilakukan normalisasi pada array tersebut dimana value - value yang ada akan berubah menjadi 0 - 1. Pada bagian label, data yang ada akan diconvert menjadi sebuah array berukuran 10 yang berisi 0 semuanya kecuali array ke-x dimana x adalah nilai dari label tersebut yang akan bernilai 1. Dataset yang telah disediakan MNIST sudah berbentuk format sama seperti diatas, hanya perlu dinormalisasi.

### 3.4 Experiment

Eksperimen ini dilakukan dengan membuat tiga model Neural Network dimana model yang pertama memiliki 1 hidden layer, model yang kedua memiliki 2 hidden layer, dan model ketiga memiliki 3 hidden layer.

#### 1. Neural Network dengan 1 *Hidden Layer*




Figure 5: Grafik akurasi dengan 1 hidden layer

Dari model diatas didapatkan akurasi tertinggi 95% yaitu pada iteration ke 8.

	0	1	2	3	4	5	6	7	8	9
0	1178	1	5	1	8	15	23	13	5	10
1	0	1312	7	2	2	1	1	7	12	3
2	4	3	1076	32	3	3	10	41	17	1
3	1	2	7	1197	4	11	2	18	11	8
4	0	1	1	0	1165	0	3	12	3	31
5	1	1	1	11	1	1088	21	7	11	6
6	4	6	2	2	6	6	1153	2	4	1
7	0	5	2	2	4	0	0	1218	4	6
8	1	4	2	13	1	4	5	2	1195	17
9	0	2	0	11	6	7	2	20	10	1208

Figure 6: Confusion Matrix Model dengan 1 hidden layer

## 2. Neural Network dengan 2 Hidden Layer




Figure 7: Grafik akurasi dengan 2 hidden layer

Model dengan 2 hidden layer ini memiliki akurasi tertinggi 96% yaitu pada iteration ke 15.

	0	1	2	3	4	5	6	7	8	9
0	1222	4	2	1	1	1	7	0	7	5
1	0	1372	5	4	2	0	2	4	1	1
2	7	8	1166	10	1	1	4	10	10	2
3	2	5	5	1187	0	14	1	13	8	11
4	2	4	1	0	1147	1	4	5	3	34
5	3	1	1	7	1	1057	10	2	6	14
6	10	2	2	1	8	11	1228	1	1	1
7	1	3	2	2	9	1	1	1266	3	11
8	4	5	0	10	2	6	5	1	1152	15
9	9	1	1	4	13	5	0	9	11	1132

Figure 8: Confusion Matrix Model dengan 2 hidden layer

### 3. Neural Network dengan 3 Hidden Layer

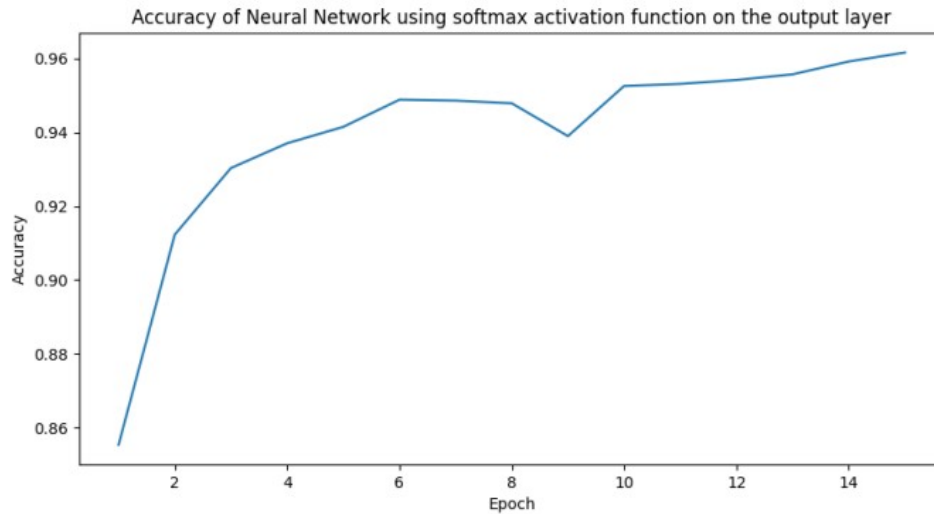


Figure 9: Grafik akurasi dengan 3 hidden layer

Model dengan 3 hidden layer ini memiliki akurasi tertinggi 96.164% yaitu pada iteration ke 15.

	0	1	2	3	4	5	6	7	8	9
0	1218	0	7	0	1	1	5	0	2	2
1	0	1349	22	1	4	2	4	7	6	0
2	4	1	1186	1	0	0	1	5	1	2
3	1	4	55	1092	2	20	2	10	7	10
4	4	1	4	0	1166	2	4	3	2	12
5	11	2	5	5	2	1106	11	1	4	6
6	10	0	5	1	4	14	1182	1	0	2
7	1	2	22	5	4	0	0	1284	0	4
8	8	2	26	6	2	14	7	1	1121	6
9	8	2	2	4	16	7	3	10	6	1180

Figure 10: Confusion Matrix Model dengan 3 hidden layer

Berdasarkan ketiga eksperimen yang telah dilakukan dapat dilihat bahwa perbedaan diantara ketiganya sangatlah kecil. Namun, tetap diputuskan untuk menggunakan model dengan 2 hidden layer yang memiliki tingkat akurasi lebih tinggi.

## 4 Result and Analysis


Kami telah membuat sebuah software dimana user dapat secara bebas menggambar di canvas yang telah disediakan dan software tersebut akan memprediksi gambar apa yang telah dibuat oleh user.

Handwritten number recognition

Clear Predict

Prediction Result

The result is 4




0) [1.74421186e-05]  
1) [0.00059805]  
2) [8.88428218e-06]  
3) [3.63729209e-09]  
4) [0.99921931]  
5) [3.47122562e-06]  
6) [4.50686054e-05]  
7) [3.53258105e-05]  
8) [2.29943027e-05]  
9) [4.94497833e-05]

Handwritten number recognition

Clear Predict

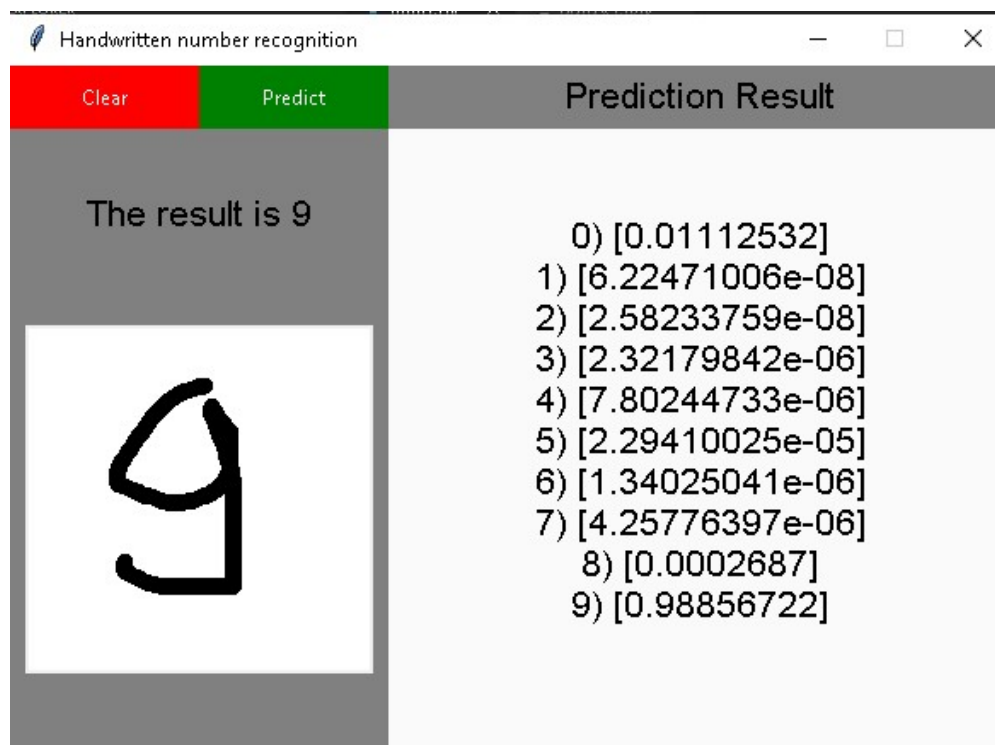
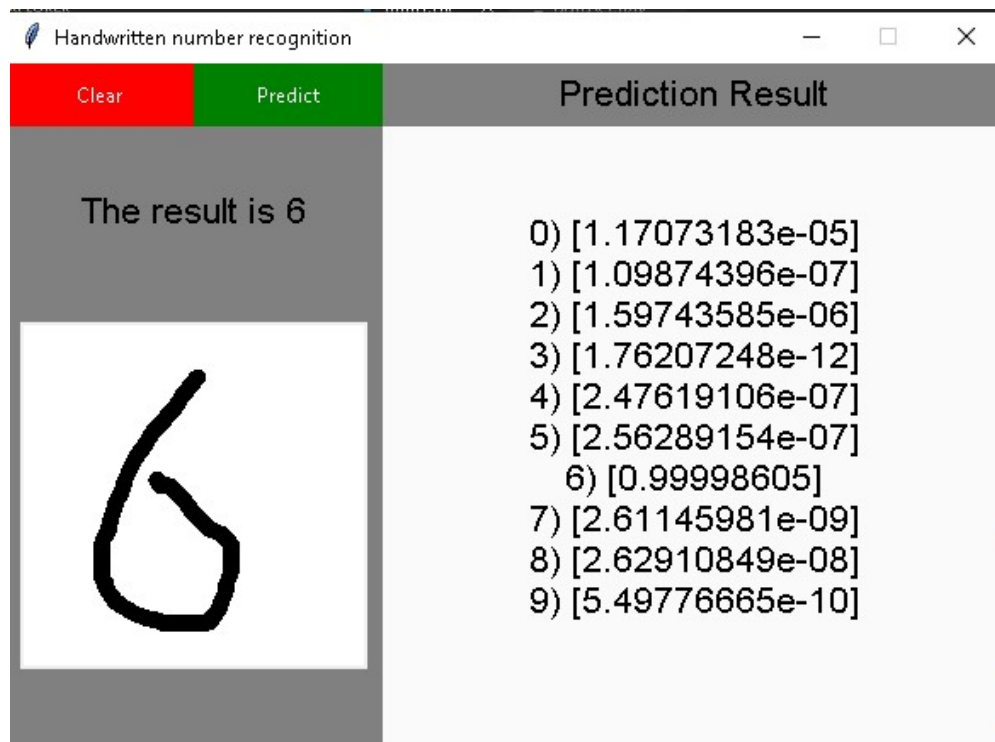
Prediction Result

The result is 0



0) [0.99705233]  
1) [1.95401947e-05]  
2) [5.78525256e-05]  
3) [8.63412794e-07]  
4) [0.00011901]  
5) [4.99888899e-07]  
6) [0.00011977]  
7) [9.19375345e-05]  
8) [7.03685378e-07]  
9) [0.00253749]





Software yang telah dibuat memiliki button clear dan predict dimana ketika user menekan tombol predict maka software akan melakukan screenshot pada gambar di canvas dan akan mengeluarkan hasil prediksi dengan nilai softmax di bagian kanan

## 5 Conclusion

Berdasarkan eksperimen yang telah dilakukan, ditentukan bahwa model yang telah dibuat bekerja dengan optimal ketika menggunakan 2 hidden layer dengan masing - masing layer memiliki 250 neuron yang telah menghasilkan model dengan tingkat akurasi sekita 99%. Software yang telah dibuat juga telah dites dengan menggambar secara pribadi dan menghasilkan prediksi yang sangat akurat walaupun belum sempurna. Selain untuk digit recognition, model ini juga dapat digunakan untuk merecognize gambar - gambar lain, tergantung dataset yang digunakan.

## References

- Shin, H., Lee, J. K., Kim, J., Kim, J. (2017). Continual learning with deep generative replay. *Advances in neural information processing systems*, 30.
- Zeng, G., Chen, Y., Cui, B., Yu, S. (2019). Continual learning of context-dependent processing in neural networks. *Nature Machine Intelligence*, 1(8), 364-372.
- Nguyen, C. V., Li, Y., Bui, T. D., Turner, R. E. (2017). Variational continual learning. *arXiv preprint arXiv:1710.10628*.
- Cossu, A., Carta, A., Bacciu, D. (2020, July). Continual learning with gated incremental memories for sequential data processing. In *2020 International Joint Conference on Neural Networks (IJCNN)* (pp. 1-8). IEEE.
- Stern, M., Pinson, M. B., Murugan, A. (2020). Continual learning of multiple memories in mechanical networks. *Physical Review X*, 10(3), 031044.
- Smith, J., Baer, S., Kira, Z., Dovrolis, C. (2019). Unsupervised continual learning and self-taught associative memory hierarchies.
- Aljundi, R. (2019). Continual learning in neural networks. *arXiv preprint arXiv:1910.02718*.
- Rostami, M., Kolouri, S., Pilly, P., McClelland, J. (2020, April). Generative continual concept learning. In *Proceedings of the AAAI Conference on Artificial Intelligence* (Vol. 34, No. 04, pp. 5545-5552).
- Ehret, B., Henning, C., Cervera, M. R., Meulemans, A., Von Oswald, J., Grewe, B. F. (2020). Continual learning in recurrent neural networks. *arXiv preprint arXiv:2006.12109*.
- Vuorio, R., Cho, D. Y., Kim, D., Kim, J. (2018). Meta continual learning. *arXiv preprint arXiv:1806.06928*.
- Ostapenko, O., Rodriguez, P., Caccia, M., Charlin, L. (2021). Continual learning via local module composition. *Advances in Neural Information Processing Systems*, 34, 30298-30312.
- Le Cun, Y., Jackel, L. D., Boser, B., Denker, J. S., Graf, H. P., Guyon, I., ... Hubbard, W. (1989). Handwritten digit recognition: Applications of neural network chips and automatic learning. *IEEE Communications Magazine*, 27(11), 41-46.
- LeCun, Y., Jackel, L. D., Bottou, L., Cortes, C., Denker, J. S., Drucker, H., ... Vapnik, V. (1995). Learning algorithms for classification: A comparison on handwritten digit recognition. *Neural networks: the statistical mechanics perspective*, 261(276), 2.
- Bottou, L., Cortes, C., Denker, J. S., Drucker, H., Guyon, I., Jackel, L. D., ... Vapnik, V. (1994, October). Comparison of classifier methods: a case study in handwritten digit recognition. In *Proceedings of the 12th IAPR International Conference on Pattern Recognition*, Vol. 3-Conference C: Signal Processing (Cat. No. 94CH3440-5) (Vol. 2, pp. 77-82). IEEE.
- Fukushima, K. (2003). Neocognitron for handwritten digit recognition. *Neurocomputing*, 51, 161-180.
- Ciresan, D. C., Meier, U., Gambardella, L. M., Schmidhuber, J. (2011, September). Convolutional neural network committees for handwritten character classification. In *2011 International conference on document analysis and recognition* (pp. 1135-1139). IEEE.